Lect 6 Stat

Made By : Ahmed Tamer

تمهيد

في المحاضرة اللي فاتت (Lecture 5) اتعلمنا إزاي بناخد عينة من مجتمع كبير وبنحسب منها متوسط العينة $\bar{X}$. وعرفنا إن $\bar{X}$ بتقرّب من μ — متوسط المجتمع الحقيقي.

بس دلوقتي فيه سؤال جديد بيطرح نفسه:

$\bar{X}$:

دي كأداة بتقدّر بيها μ — بس هي أداة كويسة قد إيه؟ وإيه اللي بيخلي أداة تقدير معينة أحسن من غيرها؟

ده هو بالظبط موضوع المحاضرة دي — إنها بتشرح **خصائص المُقدِّرات الجيدة** وبتحدد المعايير اللي بنقيّم بيها أي أداة تقدير.

جدول الرموز ال هتقابلك :

عربي	English	الرمز
المُقدِّر	Estimator	$\hat{\theta}$
التقدير	Estimate	الرقم الناتج
المعامل	Parameter	θ
مجموعة القيم الممكنة	Space of Parameters	Ω
المُقدِّر غير المتحيز	Unbiased Estimator	UE
التحيز	Bias	$\text{Bias}(\hat{\theta}) = E[\hat{\theta}] - \theta$
المُقدِّر غير المتحيز مقاربياً	Asymptotically Unbiased Estimator	AUE
المُقدِّر المتسق	Consistent Estimator	CE
التقارب الاحتمالي	Convergence in Probability	$\xrightarrow{(p)}$
متوسط مربع الخطأ	Mean Squared Error	MSE
التباين	Variance	$\text{Var}(\hat{\theta})$
الاتساق بمتوسط مربع الخطأ	MSE Consistency	—
الاتساق في المتوسط التربيعي	Consistency in Quadratic Mean	—
الإحصاء الكافي	Sufficient Statistic	Y
دالة الكثافة الاحتمالية	Probability Density Function	$f(x; \theta)$
عينة عشوائية	Random Sample	r.s.
إذا وفقط إذا	If and Only If	iff
النهاية	Limit	lim

قبل ما نبدأ — 3 مصطلحات أساسية لازم تفهمهم كويس:

Parameter = **المعامل:** القيمة الحقيقية الثابتة للمجتمع اللي بنحاول نعرفها. مثلاً μ (متوسط المجتمع) أو σ^2 (تباين المجتمع). parameter عشان الكلام يكون عام ينطبق على أي **(ثيتا) θ** بالحرف اليوناني parameter في المحاضرة دي بيعبّروا عن أي مش بس المتوسط.

Estimator = **المُقدِّر:** الأداة أو المعادلة اللي بنستخدمها عشان نحسب تقدير للـ Parameter هي الأداة اللي $\bar{X}$ من العينة. مثلاً فوق الحرف دي علامة إن الحاجة (القبعة) Hat والـ — **(ثيتا هات) $\hat{\theta}$** بـ Estimator في المحاضرة بيرمزوا للـ μ. بنقدّر بيها دي تقدير مش القيمة الحقيقية.

Estimate = **التقدير:** النتيجة الرقمية اللي بتطلع من الـ Estimator وطلعت $\bar{X}$ 7.71 لما بتطبقه على البيانات. مثلاً لو حسبت — ده هو الـ Estimate.

يعني الفرق ببساطة:

- **θ** = القيمة الحقيقية للمجتمع (مجهولة)
- **$\hat{\theta}$** = الأداة اللي بنستخدمها للتقدير (معادلة)
- **النتيجة الرقمية** = الـ Estimate

دلوقتي خليني أشرح المحاضرة.

أولاً: خصائص المُقدِّرات — Some Properties of Estimators

المحاضرة دي بتشرح **4 خصائص** ممكن يتميز بيها أي Estimator. وعشان تفهم ليه الخصائص دي مهمة — لازم تفهم السياق الأول:

لو عندنا parameter زي μ مجهول ومحتاجين نقدّره من عينة — ممكن نستخدم طرق تقدير مختلفة. مثلاً ممكن نستخدم $\bar{X}$ (متوسط العينة)، أو Median (الوسيط)، أو أي طريقة تانية. السؤال: إيه الطريقة الأفضل؟

الخصائص الأربعة دول بتجاوب على السؤال ده.

الخاصية الأولى — Unbiased Estimator (UE) = المُقدِّر غير المتحيز

> *UNBIASED ESTIMATOR (UE): An estimator $\hat{\theta}$ is an UE of the unknown parameter θ, if*
>
> *$E[\hat{\theta}] = \theta$ for all $\theta \in \Omega$*
>
> *Otherwise, it is a Biased Estimator of θ.*
>
> *$Bias(\theta) = E[\hat{\theta}] - \theta \rightarrow$ Bias of $\hat{\theta}$ for estimating θ*
>
> *If $\hat{\theta}$ is UE of θ, $Bias(\theta) = 0$.*

الرموز الجديدة — خد بالك:

E[θ̂] = القيمة المتوقعة للمُقدِّر — Expected Value of the Estimator.

ده معناه: لو اخدنا عينات كتيرة جداً وحسبنا θ̂ من كل عينة — متوسط كل النتايج دي هو E[θ̂].

θ (ثيتا) =

القيمة الحقيقية للـ Parameter في المجتمع.

Ω (أوميجا) =

مجموعة كل القيم الممكنة لـ θ — يعني المجال الكلي للـ Parameter.

Bias =

التحيز — مقياس بيقولنا بُعد الـ Estimator عن القيمة الحقيقية في المتوسط.

الفكرة الأساسية :

تخيل إنك بتحاول تقدير μ (متوسط المجتمع). اخدت عينة وحسبت X̄ وطلعت مثلاً 7.50$. المجتمع الحقيقي μ = 7.71$. الفرق = 0.21$.

سؤال: هل الفرق ده بالصدفة؟ أم إن الـ Estimator اللي بتستخدمه دايماً بيديك قيم أقل أو أكبر من الحقيقة؟

لو اخدت **عينات كتيرة جداً** وحسبت X̄ من كل عينة — ومتوسط كل X̄ دي = μ بالظبط — يبقى X̄ هي **Unbiased Estimator** لـ μ.

لكن لو متوسط كل X̄ دي = قيمة مختلفة عن μ — يبقى X̄ في الحالة دي **Biased Estimator**.

معادلة الـ Bias:

$$\text{Bias}(\hat{\theta}) = E[\hat{\theta}] - \theta$$

يعني الـ Bias هو الفرق بين متوسط ما بيطلع من الـ Estimator والقيمة الحقيقية للـ Parameter.

- لو **Bias = 0** → الـ **Unbiased** Estimator
- لو **Bias > 0** → الـ Estimator بيبالغ في التقدير — **Overestimates**
- لو **Bias < 0** → الـ Estimator بيقلل من التقدير — **Underestimates**

وبالتالي الشرط الرسمي للـ Unbiased Estimator هو:

$$E[\hat{\theta}] = \theta \text{ for all } \theta \in \Omega$$

يعني القيمة المتوقعة للـ Estimator لازم تساوي القيمة الحقيقية للـ Parameter — وده لازم يكون صح لكل القيم الممكنة لـ θ مش بس لقيمة معينة.

مثال مرئي عشان تفهم:

تخيل إنك بتحاول تصوّب على هدف. الـ Parameter هو وسط الهدف.

- **Unbiased Estimator:**
  - الطلقات بتوزع حواليه الوسط — بعضها يمين وبعضها شمال، بس متوسطها بيقع في الوسط بالظبط.
- **Biased Estimator:**
  - كل الطلقات بتنزل في ناحية معينة بعيدة عن الوسط — فيه انحراف منتظم.

خد بالك على نقطة مهمة جداً:

الـ Unbiased مش معناه إن كل تقدير بيطلع صح. لأ — معناه إن **في المتوسط** على مدى عينات كتيرة بيطلع صح. قيمة العينة الواحدة ممكن تكون بعيدة.

الخاصية الثانية — Asymptotically Unbiased Estimator (AUE) = المُقدِّر غير المتحيز مقاربياً

> *ASYMPTOTICALLY UNBIASED ESTIMATOR (AUE): An estimator θ̂ is an AUE of the unknown parameter θ, if*

> *Bias(θ̂) ≠ 0 but lim(n→∞) Bias(θ̂) = 0*

الرمز الجديد:

lim(n→∞) =
النهاية عندما n يقترب من اللانهاية — **Limit as n approaches infinity.** يعني "إيه اللي بيحصل للقيمة لما حجم العينة يكبر جداً جداً لدرجة إنه يوصل للانهاية؟"

الفكرة الأساسية:

ممكن يكون عندنا Estimator فيه Bias — يعني مش Unbiased بشكل كامل. بس لما حجم العينة n يكبر جداً — الـ Bias بتاعه بتقرب من الصفر وبتختفي.

يعني:

- لما n صغير — في Bias ملحوظ
- لما n كبير — الـ Bias بتصغر
- لما n → ∞ — الـ Bias = 0

ده المعنى الحرفي لكلمة **"Asymptotically = مقاربياً"** — يعني بيقترب من القيمة المطلوبة تدريجياً كلما n كبر، لكن مش بيوصلها بالضبط إلا في النهاية.

ليه ده مهم؟

لأن في الحياة العملية مش دايماً بنلاقي Estimators تماماً Unbiased. بس لو الـ Estimator AUE — يعني Bias بتقرب من 0 كلما n كبر — ده بيبقى مقبول عملياً لأنه بيتحسن مع زيادة حجم العينة.

الفرق بين UE و AUE:

Unbiased Estimator (UE)	Asymptotically Unbiased (AUE)
Bias = 0 دايماً بغض النظر عن n	Bias ≠ 0 مع كبر n بس بتقرب من 0
مثالي من أول عينة صغيرة	بيتحسن مع كبر العينة

الخاصية الثالثة — Consistent Estimator (CE) = المُقدِّر المتسق

> *CONSISTENT ESTIMATOR (CE): An estimator $\hat{\theta}$ which converges in probability to an unknown parameter θ for all θ ∈ Ω is called a CE of θ.*

> *$\hat{\theta} \xrightarrow{(p)} \theta$.*

> *For large n, a CE tends to be closer to the unknown population parameter.*

الرمز الجديد:

$\hat{\theta} \xrightarrow{(p)} \theta$ = الـ Estimator بيتقارب احتمالياً مع θ — **Converges in Probability.** فوق السهم معناها p الـ "Probability". يعني احتمال إن الـ Estimator يبعد عن θ بمقدار معين بيصغر جداً كلما n بيكبر.

بيبقى قريب أكتر وأكتر من Estimator بيكبر، الـ n **يتقارب احتمالياً"** معناها: كلما **"converges in probability =** باحتمال بيقترب من 1 θ القيمة الحقيقية.

الفكرة الأساسية:

Consistency **الـ — كلما العينة أكبر** بتقول: **Estimator بيقدّر بشكل أدق.**

تخيل إنك بتحسب متوسط أجور الموظفين:

- لو عينتك من 5 موظفين — $\bar{X}$ ممكن تكون بعيدة عن μ.
- لو عينتك من 50 موظف — $\bar{X}$ هتبقى أقرب لـ μ.
- لو عينتك من 500 موظف — $\bar{X}$ هتبقى أقرب جداً جداً لـ μ.
- لو عينتك من 5000 موظف — $\bar{X}$ تقريباً = μ.

الـ $\bar{X}$ ده Consistent Estimator لـ μ لأنه بيتقارب منها كلما n بيكبر.

الفرق بين UE و CE:

ده سؤال مهم ومحتمل في الامتحان:

- **UE** بيتكلم عن **المتوسط** — يعني إيه اللي بيطلع في المتوسط من الـ Estimator.
- **CE** بيتكلم عن **ماذا يحصل لما** **n** يكبر — يعني هل الـ Estimator بيتقارب من القيمة الحقيقية؟

ممكن يكون Estimator:

- **UE وCE معاً:** زي μ للـ X̄ — ده الحالة المثالية.
- **UE بس مش CE:** نادر جداً.
- **CE بس مش UE:** يعني فيه Bias كبر لكن بيختفي مع n — ده بالظبط الـ AUE.
- **مش UE ومش CE:** الأسوأ.

مثال تطبيقي — Example

> *For a random sample (r.s.) of size n,*
>
> *E(X̄) = μ ⟹ X̄ is an UE of μ.*
>
> *i.e., X̄ →(p) μ*
>
> *⟹ X̄ is a CE of μ.*

r.s. هنا اختصار لـ **random sample = عينة عشوائية**.

الجزء ده بيطبق الخصائص اللي اتكلمنا عنها على المثال الأشهر والأبسط — وهو X̄ كمُقدِّر لـ μ.

الجزء الأول:

E(X̄) = μ

يعني القيمة المتوقعة لمتوسط العينة تساوي متوسط المجتمع. وده اتبت في المحاضرة اللي فاتت لما حسبنا متوسط الـ 21 عينة في مثال Tartus وطلع نفس μ.

وبما إن E(X̄) = μ — يبقى حسب تعريف الـ UE: X̄ هي **Unbiased Estimator لـ μ**.

الجزء الثاني:

X̄ →(p) μ

يعني X̄ بتتقارب احتمالياً مع μ كلما n بيكبر. وده نتيجة مباشرة من الـ Central Limit Theorem اللي اتكلمنا عنه — إن الـ Standard Error = σ/√n بيصغر كلما n بيكبر، يعني X̄ بيبقى قريب جداً من μ.

وبما إن X̄ →(p) μ — يبقى X̄ هي **Consistent Estimator لـ μ**.

الخلاصة: $\bar{X}$ هي في نفس الوقت UE وCE لـ μ. وده بيخليها الأداة المثالية لتقدير μ.

الخاصية الرابعة — Mean Squared Error (MSE) = متوسط مربع الخطأ

> *MEAN SQUARED ERROR (MSE)*
>
> *The Mean Square Error (MSE) of an estimator $\hat{\theta}$ for estimating θ is*
>
> $MSE(\hat{\theta}) = E[\theta - \hat{\theta}]^2 = Var(\hat{\theta}) + (Bias(\hat{\theta}))^2$
>
> *If $MSE(\hat{\theta})$ is smaller, $\hat{\theta}$ is a better estimator of θ.*
>
> *For two estimators, $\hat{\theta}_1$ and $\hat{\theta}_2$ of θ, if $MSE(\hat{\theta}_1) < MSE(\hat{\theta}_2)$, $\theta \in \Omega$*
>
> *$\hat{\theta}_1$ is better estimator of θ.*

الرموز :

$MSE(\hat{\theta})$ = متوسط مربع الخطأ للمُقدِّر $\hat{\theta}$.

$E[\theta - \hat{\theta}]^2$ = يعني في المتوسط إيه مربع الخطأ اللي بيعمله الـ $\hat{\theta}$. والمُقدِّر θ القيمة المتوقعة لمربع الفرق بين القيمة الحقيقية Estimator.

$Var(\hat{\theta})$ = التباين — **Variance** — بيقيس مدى تشتت قيم الـ Estimator للمُقدِّر حول متوسطها.

$(Bias(\hat{\theta}))^2$ = مربع التحيز للمُقدِّر.

الفكرة الأساسية:

الـ MSE هو مقياس شامل لجودة الـ Estimator. وبيجمع في نفسه تأثيرين اتنين:

التأثير الأول — التباين — Variance: مدى تشتت الـ Estimator. لو Estimator ليه تباين كبير — يعني قيمه بتتفرق كتير من عينة لعينة — حتى لو متوسطها صح، كل قيمة على حدة ممكن تكون بعيدة.

التأثير الثاني — مربع التحيز — $Bias^2$: مدى انحراف الـ Estimator عن القيمة الحقيقية في المتوسط.

والمعادلة بتقول:

$$MSE = Variance + Bias^2$$

وده معناه إن الـ Estimator الجيد لازم يكون عنده:

- **Variance** **صغيرة** — يعني قيمه مش بتتشتت كتير
- **Bias** **صغيرة** — يعني مش بيبعد كتير عن الحقيقة في المتوسط

المقارنة بين Estimators:

لو عندنا Estimatorين $\hat{\theta}_1$ و $\hat{\theta}_2$ بيقدّروا نفس الـ Parameter θ:

- لو **$MSE(\hat{\theta}_1) < MSE(\hat{\theta}_2)$** لكل قيم θ في Ω — يبقى **$\hat{\theta}_1$ أحسن من $\hat{\theta}_2$**.

وده منطقي جداً — اللي عنده خطأ أصغر في المتوسط هو الأفضل.

مثال عملي لفهم الـ MSE:

تخيل عندك نوعين من الميزان لقياس الوزن:

الميزان الأول: بيعطيك أرقام كتير متشتتة — يعني مرة بيقول 70 كيلو، مرة 65، مرة 75 — بس في المتوسط بيقول 70 (الوزن الحقيقي). ده عنده **Variance عالية و Bias = 0**.

الميزان الثاني: بيعطيك نفس الرقم دايماً — مثلاً 68 — بس الوزن الحقيقي 70. ده عنده **Variance = 0 و Bias = 2**.

أيهما أحسن؟ الإجابة بتعتمد على الـ MSE:

- MSE الأول = Variance كبيرة + 0 = كبيرة
- MSE الثاني = $(2)^2$ + 0 = 4

لو الـ Variance بتاعة الأول أكبر من 4 — يبقى الثاني أحسن رغم إنه متحيز!

وده هو جوهر الـ MSE — إنه بيخليك تقارن بين Estimators حتى لو واحد Unbiased والتاني Biased — لأن Bias مش المعيار الوحيد، التشتت برضو مهم.

المعيار الخامس — Mean Squared Error Consistency = الاتساق بمعيار متوسط مربع الخطأ

> *MEAN SQUARED ERROR CONSISTENCY*

> *$\hat{\theta}$ is called mean squared error consistent (or consistent in quadratic mean) if $E\{\hat{\theta} - \theta\}^2 \to 0$ as $n \to \infty$.*

> *Theorem: $\hat{\theta}$ is consistent in MSE iff*

> *i) $Var(\hat{\theta}) \to 0$ as $n \to \infty$.*

> *ii) $\lim_{(n\to\infty)} E(\hat{\theta}) = \theta$*

> *If $E\{\hat{\theta} - \theta\}^2 \to 0$ as $n \to \infty$, $\hat{\theta}$ is also a CE of θ.*

الرموز:

$E\{\hat{\theta} - \theta\}^2 \to 0$ as $n \to \infty$ = القيمة المتوقعة لمربع الفرق بين الـ Estimator والقيمة الحقيقية بتقترب من الصفر كلما n بيكبر.

iff = if and only if = يعني الشرطين الاتنين لازم يتحققوا مع بعض — **إذا وفقط إذا**.

الفكرة الأساسية:

الـ MSE Consistency هو نوع خاص من الـ Consistency — اللي بيتكلم عن إيه اللي بيحصل للـ MSE نفسها كلما n بيكبر.

الـ Estimator بيكون **MSE Consistent** لو الـ MSE بتاعته بتقرب من الصفر كلما n بيكبر. يعني الخطأ بيختفي تدريجياً مع كبر العينة.

والنظرية بتقول: الـ Estimator بيكون MSE Consistent لو شرطين اتحققوا مع بعض:

الشرط الأول: $Var(\hat{\theta}) \to 0$ as $n \to \infty$ — يعني التباين بتاعه بيقرب من الصفر كلما n بيكبر.

الشرط الثاني: $\lim_{(n\to\infty)} E(\hat{\theta}) = \theta$ — يعني القيمة المتوقعة بتقرب من القيمة الحقيقية كلما n بيكبر. وده بالظبط هو شرط الـ AUE.

الجملة الأخيرة المهمة:

> *If $E\{\hat{\theta} - \theta\}^2 \to 0$ as $n \to \infty$, $\hat{\theta}$ is also a CE of θ.*

يعني الـ MSE Consistency أقوى من الـ CE العادية — لو Estimator كان MSE Consistent، ده بيضمن إنه كمان CE. الأمر مش العكس بالضرورة.

المفهوم الأخير — Sufficient Statistics = الإحصاء الكافي

> *SUFFICIENT STATISTICS*

> *X, $f(x; \theta)$,*

> *$X_1, X_2, \ldots, X_n$*

> *$Y = U(X_1, X_2, \ldots, X_n)$ is a statistic.*

> *A sufficient statistic, Y, is a statistic which contains all the information for the estimation of θ.*

الرموز:

$f(x; \theta)$ = دالة الكثافة الاحتمالية للمجتمع — **Probability Density Function**. بتصف توزيع المجتمع وبتشمل الـ Parameter θ المجهول.

$X_1, X_2, \ldots, X_n$ = يعني الـ n قيم العينة الفردية — قيمة اللي اخدناها.

اللي بتحسب U هي $\bar{X}$ **الإحصاء**. مثلاً **Statistic =** أي دالة بتحسب من قيم العينة — وده هو الـ $Y = U(X_1, X_2, \ldots, X_n)$ = المتوسط.

الفكرة الأساسية:

لما بنحسب إحصاء زي $\bar{X}$ من العينة — بنبدأ "نلخص" البيانات. بدل ما نستخدم الـ n قيمة كلها، بنستخدم رقم واحد.

السؤال هو: هل التلخيص ده بيخسّر معلومات مهمة عن θ؟

الـ **Sufficient Statistic** هو الإحصاء اللي **مبيخسرش أي معلومة** مهمة عن θ. يعني بيلخص البيانات من غير ما يضيع أي معلومة مفيدة للتقدير.

بمعنى تاني: لو عندك Sufficient Statistic Y — فمعرفة قيمة Y بتعطيك كل المعلومات اللي موجودة في العينة كلها $X_1, X_2, \ldots, X_n$ عن الـ Parameter θ. مش محتاج القيم الفردية كلها.

مثال بسيط:

لو عايز تقدّر μ (متوسط المجتمع) — $\bar{X}$ هي Sufficient Statistic لـ μ. يعني $\bar{X}$ بتلخص كل المعلومات اللي في العينة عن μ. من غير ما تعرف كل قيمة على حدة — $\bar{X}$ لوحدها كافية للتقدير الأفضل.

ملخص جدول المقارنة بين الخصائص

الخاصية	الرمز	المعنى ببساطة	الشرط
Unbiased (UE)	$E[\hat{\theta}] = \theta$	في المتوسط بيصيب القيمة الحقيقية	Bias = 0
Asymptotically Unbiased (AUE)	lim Bias = 0	فيه Bias بس بيختفي مع كبر n	Bias → 0 as n → ∞
Consistent (CE)	$\hat{\theta} \xrightarrow{(p)} \theta$	كلما n أكبر كلما أدق	يتقارب احتمالياً مع θ
MSE Consistent	$E\{\hat{\theta}-\theta\}^2 \to 0$	الخطأ الكلي بيختفي مع كبر n	Var → 0 و lim E(θ̂) = θ
Sufficient	Y يحتوي كل المعلومات	ملخص كامل للبيانات	لا يضيع معلومات عن θ

الرموز والمصطلحات — شرح كامل

أولاً: θ (ثيتا) و θ̂ (ثيتا هات)

θ (ثيتا) = Parameter = المعامل

.هو الحرف اليوناني اللي المحاضرة بتستخدمه للتعبير عن أي **قيمة حقيقية ثابتة في المجتمع** — مجهولة ومحتاجين نقدّرها **θ**

ليه بيستخدموا θ ومش بيكتبوا μ مثلاً؟

لأن μ بتعبر عن المتوسط بس. أما θ فبتعبر عن أي **Parameter** — ممكن يكون متوسط أو تباين أو نسبة مئوية أو أي قيمة تانية. يعني الكلام بيبقى عام وينطبق على كل الحالات مش بس المتوسط.

أمثلة:

- لو θ = μ — يبقى بنتكلم عن متوسط المجتمع
- لو θ = σ² — يبقى بنتكلم عن تباين المجتمع
- لو θ = p — يبقى بنتكلم عن نسبة مئوية في المجتمع

الخلاصة: θ = القيمة الحقيقية الموجودة في المجتمع اللي مش نعرفها وعايزين نقدّرها.

θ̂ (ثيتا هات) = Estimator = المُقدِّر

قبعة فوقيه. والقبعة دي لها معنى مهم جداً في الإحصاء — بتقول إن الحاجة دي **تقدير** مش **Hat =** بس عليه θ هو نفس الحرف θ̂ القيمة الحقيقية.

يعني θ̂ هو الأداة أو المعادلة اللي بنطبقها على بيانات العينة عشان نوصل لتقدير لـ θ.

مثال ملموس:

- θ = μ (المتوسط الحقيقي للمجتمع — مجهول)
- θ̂ = X̄ (متوسط العينة — ده هو الأداة اللي بنقدّر بيها)

خد بالك الفرق الدقيق بين 3 حاجات:

الحاجة	الرمز	المعنى	مثال
Parameter	θ	القيمة الحقيقية الثابتة في المجتمع	μ = 7.71 (الحقيقي)
Estimator	θ̂	الأداة أو المعادلة اللي بنحسب بيها	X̄ = المعادلة نفسها
Estimate	الرقم الناتج	النتيجة الرقمية لما بنطبق الأداة	X̄ = 7.50 من عينة معينة

ثانياً: E[θ̂] = القيمة المتوقعة للمُقدِّر — Expected Value

هنا اختصار لـ **E** **Expected Value = القيمة المتوقعة أو التوقع الرياضي.**

E[θ̂] من كل عينة — متوسط كل النتائج دي هو θ̂ معناها: لو اخدنا عينات كتيرة جداً من نفس المجتمع — وحسبنا E[θ̂].

مثال عملي:

تخيل إنك اخدت 1000 عينة مختلفة من مجتمع متوسطه الحقيقي μ = 7.71. من كل عينة حسبت X̄. طلع معاك 1000 قيمة مختلفة لـ X̄ — بعضها 7.50، بعضها 7.80، بعضها 7.65، وهكذا.

متوسط الـ 1000 قيمة دي كلها = E[X̄].

لو E[X̄] = 7.71 — يبقى X̄ بتصيب في المتوسط. وده معناه إنها **Unbiased**.

لو E[X̄] = 7.50 — يبقى X̄ دايماً بتقدّر بأقل من الحقيقة في المتوسط. وده معناه إنها **Biased**.

خد بالك: E مش بتتحسب من عينة واحدة — هي مفهوم نظري بيقول "لو كررنا التجربة عينات لانهائية — إيه المتوسط اللي هيطلع؟"

ثالثاً: Bias(θ̂) = التحيز

> *Bias(θ̂) = E[θ̂] − θ*

Bias معناها حرفياً **التحيز أو الانحراف المنتظم.**

المعادلة بتقول:

Bias = E[θ̂] − θ

يعني = (متوسط ما بيطلع من الـ Estimator) − (القيمة الحقيقية)

الحالات الممكنة:

الحالة الأولى — Bias = 0:

Unbiased = Estimator في المتوسط بيصيب القيمة الحقيقية. وده معناه إن الـ Estimator بالظبط. يعني الـ E[θ̂] = θ **غير متحيز.**

الحالة الثانية — Bias > 0:

بيبالغ في = Overestimates في المتوسط بيعطي قيمة **أكبر** من الحقيقة. وده معناه إنه Estimator يعني الـ E[θ̂] > θ. **التقدير.**

الحالة الثالثة — Bias < 0:

بيقلّل من = Underestimates في المتوسط بيعطي قيمة **أصغر** من الحقيقة. وده معناه إنه Estimator يعني الـ E[θ̂] < θ. **التقدير.**

مثال رقمي:

μ عندنا 10. = الحقيقي Estimator، E[θ̂] = 12.

Bias = 12 − 10 = **+2**

يعني الـ Estimator ده دايماً بيبالغ بمقدار 2 وحدة في المتوسط.

رابعاً: Ω (أوميجا) = مجموعة القيم الممكنة للـ Parameter

Parameter Space = مجال أو فضاء المعاملات. هو الحرف اليوناني الكبير أوميجا، وفي الإحصاء بيعبّر عن **Ω**

يعني هو مجموعة كل القيم الممكنة والمعقولة للـ Parameter θ.

مثال:

لو θ هو نسبة الناس اللي بيصوتوا في انتخابات — النسبة دي لازم تكون بين 0% و100%. فـ Ω = [0, 1].

لو θ هو متوسط الأجور — الأجور دايماً موجبة. فـ Ω = (0, ∞).

ليه بيقول "for all θ ∈ Ω"؟

جملة "for all θ ∈ Ω" معناها "لكل قيمة ممكنة لـ θ في المجال." يعني الشرط لازم يكون صح مش لقيمة θ واحدة بس — لكن لأي قيمة ممكنة لـ θ.

ده مهم عشان الـ Estimator يكون Unbiased مش بس في حالة معينة — لكن في كل الحالات.

خامساً: lim(n→∞) = النهاية عند اللانهاية — Limit as n Approaches Infinity

Limit = النهاية. اختصار لـ **lim**

(n→∞) تحت الـ lim معناها "لما n يقترب من اللانهاية" — يعني لما حجم العينة يكبر جداً جداً لدرجة إنه يوصل للانهاية.

lim(n→∞) Bias(θ̂) = 0

الجملة دي معناها: لو حجم العينة n كبر جداً جداً — الـ Bias بتقرب من الصفر وبتختفي.

مثال لفهم الـ lim:

تخيل معادلة البيانات دي:

لما n = 10 → Bias = 0.5
لما n = 100 → Bias = 0.05
لما n = 1000 → Bias = 0.005
لما n = 10,000 → Bias = 0.0005

كلما n بيكبر — الـ Bias بتصغر وبتقرب من الصفر. ولو n وصل لـ ∞ — الـ Bias = 0.

ده معناه إن **lim(n→∞) Bias = 0** — وده هو تعريف الـ AUE.

سادساً: $\xrightarrow{(p)}$ = التقارب الاحتمالي — Convergence in Probability

> $\hat{\theta} \xrightarrow{(p)} \theta$

الرمز ده فيه جزأين:

السهم $\rightarrow$ معناه "بيتقارب من" أو "بيقترب من."

الـ (p) فوق السهم معناه "في الاحتمال — in Probability."

يعني $\hat{\theta} \xrightarrow{(p)} \theta$ معناها: "الـ Estimator بيتقارب احتمالياً من القيمة الحقيقية θ كلما n بيكبر."

ما معنى "يتقارب احتمالياً" بالضبط؟

معناها إن احتمال إن الـ Estimator يبعد عن θ بأي مقدار معين — بيصغر ويقترب من الصفر كلما n بيكبر.

بالعربي الأبسط: **كلما العينة أكبر — كلما الـ Estimator بيطلع أقرب للقيمة الحقيقية بنسبة أعلى من الوقت.**

مثال عملي:

تخيل إنك بتحسب $\bar{X}$ لتقدير $\mu = 50$.

لما $\bar{X}$: $n = 5$ ممكن تطلع 45 أو 55 أو 48 أو 53 — تشتت كبير.
لما $\bar{X}$: $n = 50$ هتبقى في الغالب بين 48 و52 — أقرب.
لما $\bar{X}$: $n = 500$ هتبقى في الغالب بين 49.5 و50.5 — أقرب جداً.
لما $\bar{X}$: $n \rightarrow \infty$ تقريباً = 50 دايماً.

ده هو معنى $\hat{\theta} \xrightarrow{(p)} \theta$.

سابعاً: MSE(θ̂) = متوسط مربع الخطأ — Mean Squared Error

> $MSE(\hat{\theta}) = E[\hat{\theta} - \theta]^2 = Var(\hat{\theta}) + (Bias(\hat{\theta}))^2$

الـ MSE مكوّن من 3 أجزاء لازم تفهم كل واحد:

الجزء الأول: $E[\hat{\theta} - \theta]^2$

$\hat{\theta} - \theta$ = الفرق بين القيمة الحقيقية والـ Estimator — يعني الخطأ في كل مرة.

$(\hat{\theta} - \theta)^2$ = بنربّع عشان — مربع الخطأ:

- نتخلص من الإشارة السالبة (الأخطاء السالبة والموجبة مش يلغوا بعض)
- نعاقب الأخطاء الكبيرة أكتر من الصغيرة (لأن $4^2 = 16$ أكبر بكتير من $2^2 = 4$)

$E[\hat{\theta} - \theta]^2$ = متوسط كل مربعات الأخطاء على مدى عينات كتيرة.

الجزء الثاني: Var(θ̂) = التباين

Var(θ̂) = تباين الـ Estimator نفسه — يعني مدى تشتت قيم الـ Estimator من عينة لعينة.

لو الـ Estimator بيعطيك نفس النتيجة تقريباً في كل عينة — Var صغير.

لو الـ Estimator بيعطيك نتايج متفرقة جداً من عينة لعينة — Var كبير.

الجزء الثالث: $(Bias(\hat{\theta}))^2$

ده مربع الـ Bias اللي اتكلمنا عنه قبل كده.

العلاقة بين الثلاثة:

$MSE = Var + Bias^2$

ده معناه إن الخطأ الكلي للـ Estimator بيتكون من مصدرين:

المصدر الأول — التشتت — Variance: حتى لو الـ Estimator Unbiased (Bias=0) — لو فيه تشتت كبير في قيمه من عينة لعينة — الـ MSE هتبقى كبيرة.

المصدر الثاني — الانحراف المنتظم — $Bias^2$: حتى لو الـ Estimator مش متشتت كتير — لو فيه انحراف منتظم عن الحقيقة — الـ MSE هتبقى كبيرة.

مثال بالأرقام:

عندنا Estimatorين بيقدّروا $\theta = 10$:

$\hat{\theta}_1$: Var = 9، Bias = 0
$MSE = 9 + 0^2 = \mathbf{9}$

$\hat{\theta}_2$: Var = 2، Bias = 2
$MSE = 2 + 2^2 = 2 + 4 = \mathbf{6}$

رغم إن $\hat{\theta}_1$ هي **Unbiased** و**Biased** $\hat{\theta}_2$ — إلا إن $\hat{\theta}_2$ أحسن لأن MSE بتاعتها أصغر!

وده هو الدرس المهم من الـ MSE: Unbiased مش كافي لوحده. التشتت برضو مهم. والـ MSE بيوازن بين الاتنين.

ثامناً: MSE Consistency = $E\{\hat{\theta} - \theta\}^2 \to 0$ as $n \to \infty$

> $E\{\hat{\theta} - \theta\}^2 \to 0$ as $n \to \infty$

الجملة دي بتقول إن الـ MSE نفسها بتقرب من الصفر كلما n بيكبر.

اللي معناه: كلما العينة أكبر — كلما الخطأ الكلي بيصغر ويختفي.

ليه ده أهم من مجرد CE؟

لأن الـ MSE Consistency بيقولك إن **الخطأ الكلي** — اللي بيشمل التشتت والانحراف مع بعض — بيختفي. مش بس إن الـ Estimator بيقترب من θ احتمالياً زي الـ CE العادية.

تاسعاً: Var(θ̂) → 0 as n → ∞ = التباين بيقرب من الصفر

ده الشرط الأول من شرطين لازمين عشان الـ Estimator يكون MSE Consistent.

Var(θ̂) → 0 as n → ∞ معناها: كلما قيم الـ n بيكبر — كلما Estimator بتتشتت أكتر حول قيمة معينة ومش بتتجمع.

مثال عملي:

الـ Standard Error للمتوسط = σ/√n.

لما n = 4 → Standard Error = σ/2
لما n = 100 → Standard Error = σ/10
لما n = 10,000 → Standard Error = σ/100
لما n → ∞ → Standard Error → 0

يعني التشتت بيختفي مع كبر العينة. وده بالظبط معناه Var(θ̂) → 0.

عاشراً: lim(n→∞) E(θ̂) = θ

ده الشرط الثاني لـ MSE Consistency.

lim(n→∞) E(θ̂) = θ معناها: كلما n بيكبر — متوسط قيم الـ Estimator بيقترب من القيمة الحقيقية θ.

خد بالك: الشرط ده هو بالظبط تعريف الـ AUE اللي اتكلمنا عنه.

يعني الـ MSE Consistency بيشترط:

- إن التشتت يختفي مع كبر n (الشرط الأول)
- وإن الـ Estimator يكون AUE على الأقل (الشرط الثاني)

الحادي عشر: $Y = U(X_1, X_2, \ldots, X_n)$ = الإحصاء — Statistic

> *$Y = U(X_1, X_2, \ldots, X_n)$ is a statistic.*

$X_1, X_2, \ldots, X_n$ = القيم الفردية للعينة — يعني كل قيمة اتقاست على حدة.

$U(X_1, X_2, \ldots, X_n)$ = دالة بتحسب من القيم دي كلها. يعني بتاخد كل القيم وبتحسب منها رقم واحد.

Y = النتيجة الناتجة — وده هو الـ **Statistic = الإحصاء.**

مثال:

$X_1 = 7$، $X_2 = 8$، $X_3 = 7$، $X_4 = 9$، $X_5 = 8$

$Y = \bar{X} = (7+8+7+9+8)/5 = 7.8$

هنا الدالة U هي المتوسط. والـ Statistic Y = 7.8.

الثاني عشر: Sufficient Statistic = الإحصاء الكافي

> *A sufficient statistic, Y, is a statistic which contains all the information for the estimation of θ.*

Sufficient = يعني يكفي لوحده — **كافٍ.**

Sufficient Statistic عن الـ **كل المعلومات الموجودة في العينة** هو الإحصاء اللي بيحتوي على Parameter θ.

الفرق بين Statistic عادي و Sufficient Statistic:

لما بتحسب أي إحصاء من العينة — بتلخص البيانات. وفي التلخيص ده ممكن تضيع معلومات.

مثلاً:

- لو عندك عينة: 5، 7، 9 — والـ Statistic هو الرقم الأوسط (Median) = 7. فضيّعت معلومات عن 5 و9.
- لو الـ Statistic هو $\bar{X} = (5+7+9)/3 = 7$ — برضو ممكن تضيع معلومات.

لكن لو الـ **Sufficient** Statistic — معناه إن مفيش معلومات اتضاعت عن θ. كل اللي محتاجه لتقدير θ موجود في Y.

مثال بسيط:

لو $\theta = \mu$ (متوسط المجتمع) — ثبت رياضياً إن $\bar{X}$ هي Sufficient Statistic لـ μ. يعني $\bar{X}$ لوحدها بتحتوي على كل المعلومات اللي في العينة كلها عن μ. مش محتاج القيم الفردية كلها.

جدول مقارنة شامل بين كل الرموز

الرمز	الاسم بالإنجليزي	الاسم بالعربي	المعنى ببساطة
θ	Parameter	المعامل	القيمة الحقيقية المجهولة في المجتمع
$\hat{\theta}$	Estimator	المُقدِّر	الأداة أو المعادلة اللي بنقدّر بيها
$E[\hat{\theta}]$	Expected Value of Estimator	القيمة المتوقعة للمُقدِّر	متوسط الـ Estimator على عينات لانهائية

الرمز	الاسم بالإنجليزي	الاسم بالعربي	المعنى ببساطة
$Bias(\hat{\theta})$	Bias	التحيز	الفرق بين المتوسط والحقيقة $E[\hat{\theta}] - \theta =$
Ω	Parameter Space	مجال المعاملات	مجموعة كل القيم الممكنة لـ θ
$\lim(n\to\infty)$	Limit as n approaches infinity	النهاية عند اللانهاية	ماذا يحصل للقيمة لما n يكبر جداً
$\to(p)$	Convergence in Probability	التقارب الاحتمالي	الـ Estimator بيقترب من θ كلما n كبر
$MSE(\hat{\theta})$	Mean Squared Error	متوسط مربع الخطأ	$Var(\hat{\theta}) + Bias^2(\hat{\theta})$
$Var(\hat{\theta})$	Variance of Estimator	تباين المُقدِّر	مدى تشتت قيم الـ Estimator من عينة لعينة
$E\{\hat{\theta}-\theta\}^2 \to 0$	MSE Consistency condition	شرط الاتساق بالـ MSE	الخطأ الكلي بيختفي مع كبر n
$Y = U(X_1,\ldots,Xn)$	Statistic	الإحصاء	دالة بتحسب من قيم العينة
Sufficient Statistic	Sufficient Statistic	الإحصاء الكافي	إحصاء بيحتوي كل المعلومات عن θ
r.s.	Random Sample	العينة العشوائية	عينة اختيرت بشكل عشوائي
iff	If and Only If	إذا وفقط إذا	شرط في الاتجاهين
$f(x; \theta)$	Probability Density Function	دالة الكثافة الاحتمالية	بتصف توزيع المجتمع